

# Creación eficiente de modelos estadísticos para detección automática y precisa de entidades nombradas

*Horacio Miguel Gómez (L : 50825)*

*Juan Pablo Orsay (L : 49373)*

*Proyecto final de carrera*

*2019-11-20*

## Índice

<b>1</b>	<b>Introducción</b>	<b>2</b>
<b>2</b>	<b>Definición del problema</b>	<b>3</b>
2.1	Conceptos básicos . . . . .	3
2.2	Los datos son el problema . . . . .	5
<b>3</b>	<b>Estado del arte</b>	<b>7</b>
3.1	Stack de software . . . . .	7
3.2	El pipeline . . . . .	7
3.3	Algoritmo de tokenización . . . . .	7
3.4	Modelos basados en reglas . . . . .	8
3.5	Modelos de «deep-learning» . . . . .	9
3.6	Usando el modelo estadístico . . . . .	14
<b>4</b>	<b>NERd (Implementación)</b>	<b>16</b>
4.1	Vista lógica . . . . .	16
4.2	Vista de proceso . . . . .	29
4.3	Vista de desarrollo . . . . .	30
4.4	Vista física . . . . .	31
4.5	Escenarios . . . . .	32
<b>5</b>	<b>Resultados</b>	<b>33</b>
5.1	Métrica: precisión y exhaustividad . . . . .	33
<b>6</b>	<b>Discusión</b>	<b>35</b>
6.1	Tipos de entidades relevantes . . . . .	35
6.2	Seed en los types . . . . .	35
6.3	Linkeo de entidades con Knowledge Base . . . . .	35
6.4	Mejora live vs offline . . . . .	35
6.5	Utilidad de la herramienta . . . . .	35
<b>7</b>	<b>Conclusiones</b>	<b>37</b>
7.1	Examples . . . . .	37

# 1. Introducción

El **Reconocimiento de Entidades Nombradas (NER)** es una subtask de extracción de información que busca ubicar las menciones de **entidades nombradas** en textos no estructurados. Estas entidades son luego clasificadas en categorías predefinidas como los nombres de personas, organizaciones, ubicaciones, expresiones de tiempo, cantidades, valores monetarios, porcentajes, entre otras.

Por ejemplo en el siguiente texto:

Este es el proyecto final de carrera de los alumnos Gómez y Orsay para el Instituto Tecnológico de Buenos Aires.

Se pueden detectar 3 entidades:

- **Gómez:** Persona
- **Orsay:** Persona
- **Instituto Tecnológico de Buenos Aires:** Organización

El estado-del-arte de los sistemas *NER* producen un rendimiento casi humano (Marsh & Perzanowski, 1998) (cerca al 95 % de *valor-F*).

A pesar de estos altos valores de rendimiento, la industria tiene dificultades para poder capitalizar la efectividad de dichos sistemas y algoritmos. Es por ello que en este trabajo final hemos tomado la decisión de implementar una plataforma Open Source para revertir esta situación.

## 2. Definición del problema

### 2.1. Conceptos básicos

#### 2.1.1. Entidad nombrada

En *extracción de información*, una *entidad nombrada* es un objeto del mundo real como lo son personas, ubicaciones, organizaciones, productos, etc; que pueden denotarse con un nombre propio. La entidad puede ser abstracto o tener existencia física. Ejemplos de entidades nombradas son «Mauricio Macri», «Ciudad Autónoma de Buenos Aires», «Apple Macbook». También se suele definir sencillamente como aquellas entidades que se pueden ver como instancias de entidad (por ejemplo, la Ciudad Autónoma de Buenos Aires es una instancia de una ciudad).

##### 2.1.1.1. Definición formal

Formalmente el concepto de «entidad nombrada» se deriva de la definición del filósofo estadounidense **Saul Kripke** de **designador rígido** (Kripke, 1980) que forma parte de la lógica modal y filosofía del lenguaje.

Un designador rígido designa a una misma entidad en todos los mundos posibles en los que esa entidad existe, y no designa nada en aquellos mundos en los que no existe.

Algunos ejemplos de designadores rígidos son:

- Nombres propios como «Saul Kripke», «Júpiter», «Londres», «4» y «Hércules».
- Descripciones definidas matemáticas como «la raíz cuadrada de 4» y « $8 - 2$ ».
- Nombres de clases naturales como «agua» y «bronce».
- Nombres de sensaciones como «dolor» y «alegría».

Por el contrario, los **designadores flácidos** pueden designar diferentes cosas en diferentes mundos posibles y **no** son *entidades nombradas*.

Por ejemplo en la oración: «Mauricio Macri es el presidente de Argentina»:

- «Mauricio Macri» y «Argentina» son *entidades nombradas*, ya que se refieren a objetos específicos.
- «presidente» y «presidente de Argentina» no son *entidades nombradas*, ya que pueden usarse para referirse a muchos objetos diferentes en mundos diferentes:
  - «presidente» puede ser de diferentes países u organizaciones que se refieren a diferentes personas.
  - «presidente de Argentina», si bien hace referencia a un mismo país, puede ser de diferentes períodos presidenciales que se refieren a diferentes personas.

##### 2.1.1.2. Definición no estricta

Existe un acuerdo general en la comunidad *NER* para considerar como entidades nombradas a otro tipos de entidades que violan el principio de designador rígido. Ejemplos de esto son:

- expresiones temporales como «3 de febrero», «2019».
- expresiones numéricas, como cantidades de dinero y otros tipos de unidades

- expresiones que según contexto denotan una entidad rígida pero no en sí mismas. Por ejemplo «Alfredo Fortabat, empresario argentino, fundador de la compañía cementera Loma Negra.» puede ser considerada una entidad nombrada, sin embargo, el término «Fortabat» por sí sólo podría referirse a su viuda «María Amalia Lacroze de Fortabat», al museo de arte «Museo Fortabat» o a la localidad Argentina «Villa Alfredo Fortabat».

En este trabajo hemos priorizado esta definición laxa para tener una mayor expresividad en los tipos de entidades que vamos a detectar. Por lo tanto, en adelante, la definición del término «entidad nombrada» será utilizada bajo una definición no estricta.

### **2.1.2. Reconocimiento de entidades**

El Reconocimiento de entidades nombradas a menudo se divide en dos problemas distintos:

1. Detección de nombres
2. Clasificación de los nombres según el tipo de entidad al que hacen referencia a (persona, organización, ubicación y otro)

En la primera fase los nombres se definen como tramos contiguos de tokens, sin anidamiento, de modo que «Instituto Tecnológico de Buenos Aires» es una entidad única, sin tener en cuenta el hecho de que dentro de esta, la subcadena «Buenos Aires» es en sí otra entidad.

Esta forma de definir el problema, lo reduce a un problema de segmentación.

La segunda fase requiere elegir una ontología para organizar categorías de cosas.

#### **2.1.2.1. Dificultades para encontrar mejores algoritmos**

El estado del arte de NER desde 2014 con la introducción de Redes Neuronales ha llegado a una meseta (Honnibal, 2017). En los últimos años el diferencial capitalizado por los diferentes grupos de investigación especializados fue muy reducido. Como puede verse en la siguiente figura:

SYSTEM	TYPE	NER F
spaCy en_core_web_sm (2017)	neural	85.67
spaCy en_core_web_lg (2017)	neural	86.42
Strubell et al. (2017)	neural	<b>86.81</b>
Chiu and Nichols (2016)	neural	86.19
Durrett and Klein (2014)	neural	84.04
Ratinov and Roth (2009)	linear	83.45

**Figura 1:** Principales avances del estado del arte para NER en los últimos años

Las razones por las cuales esto ocurre escapa el alcance de este trabajo pero se pueden resumir bajo la ley de los rendimientos decrecientes. Se necesita mucho esfuerzo académico para obtener una mejora marginal en el estado del arte actual.

Es por esto que resulta interesante analizar que otro tipo de problemas podemos atacar en este trabajo.

#### 2.1.2.2. Dominios del problema

Existe un hilo conductor en el que todas las investigaciones mencionadas en la figura 1 coinciden; incluso los sistemas NER más avanzadas son frágiles, dado que los sistemas NER desarrollados para un dominio no suelen comportarse bien en otros dominios (Poibeau & Kosseim, 2000). La puesta a punto de un sistema NER para un nuevo dominio conlleva un esfuerzo considerable. Esto es cierto para modelos basados en reglas y para sistemas estadísticos.

Se entiende por dominio a todos los textos que en su conjunto forman un corpus común. Ejemplos de estos son «Noticias periodísticas», «Textos jurídicos», «Reportes militares», «Papers académicos», etc.

## 2.2. Los datos son el problema

Por todo lo mencionado, es evidente que el cuello de botella para el avance de esta y muchas áreas de la IA es el la captura de datos, no los algoritmos (Montani, 2016).

En particular para el estado actual del arte de NER es necesario tener el cuerpo de textos a analizar (Corpus) tagueado de tal manera que se conozcan previamente los nombres y tipos de entidades

de un subconjunto de textos para inferir sobre el resto.

Este aprendizaje se carga en lo que se reconoce como un «Modelo estadístico» y es a ese modelo al que se le pide inferir nuevos resultados. En nuestra experiencia los modelos pre-entrenados de las diferentes plataformas / librerías / frameworks y trabajos académicos resultan siempre insuficientes para el uso en producción de los mismos.

De esta manera queda bien definido el problema que queremos atacar (y el título de este trabajo)

Creación eficiente de modelos estadísticos para detección automática y precisa de entidades nombradas

Para este fin se creó un sistema informático que permitirá obtener resultados a la altura de las soluciones del estado del arte para cualquier corpus de documentos que posea una cantidad necesaria de datos.

### 3. Estado del arte

El análisis del estado del arte fue basado en la definición del problema.

#### 3.1. Stack de software

Python es el lenguaje más utilizado para resolver problemas de Machine Learning, en especial NLP ("The state of the octoverse," 2019)


Spacy es el framework mejor ranqueado para la tarea de NLP ("The state of the octoverse," 2019) y sabemos por la Figura 1 que obtiene resultados a-la-par del estado del arte actual.

Además la implementación de spacy es robusta y orientada a la creación de aplicaciones para producción, a diferencia de muchas otras librerías de NLP que sólo se utilizan con fines académicos.

#### 3.2. El pipeline

Todas las operaciones de análisis de lenguaje natural sobre textos no estructurados, tienen como primer paso el de separar el los mismos en tokens. Luego, el documento se procesa en varios pasos diferentes que consisten en el «pipeline de procesamiento». Usualmente los pasos consisten en un etiquetador, un analizador sintáctico y un reconocedor de entidades en el caso de NER.

Cada componente del pipeline devuelve el Doc procesado, que luego se pasa al siguiente componente.



**Figura 2:** Pipeline standard para los algoritmos de NER

En este capítulo estudiaremos la morfología de dicho pipeline.

#### 3.3. Algoritmo de tokenización

Para tokenizar un texto de manera correcta no basta con separar el mismo en espacios. Dependiendo el lenguaje que se esté estudiando, existen «excepciones» a esta regla y otros caracteres que representan separaciones entre tokens según el contexto de los mismos.

En particular, spaCy posee algoritmo de tokenización inteligente que puede ser resumido de la siguiente manera:

1. Iterar sobre subcadenas separadas por espacios en blanco.
2. Comprobar si existe una regla definida explícitamente para esta subcadena. Si existe, usarla.

3. De lo contrario, intentar consumir un prefijo. Si consumimos un prefijo, regrese al punto#2, para que los casos especiales siempre tengan prioridad.
4. Si no se puede consumir un prefijo, intente consumir un sufijo y luego regrese al punto #2.
5. Si no se puede consumir un prefijo ni un sufijo, buscar un caso especial.
6. Buscar una coincidencia de token
7. Buscar «infijos» - cosas como guiones, etc. y dividir la subcadena en tokens en todos los infijos.
8. Una vez que no se pueda consumir más de la cadena, tratarla como un token único.

Ejemplo:

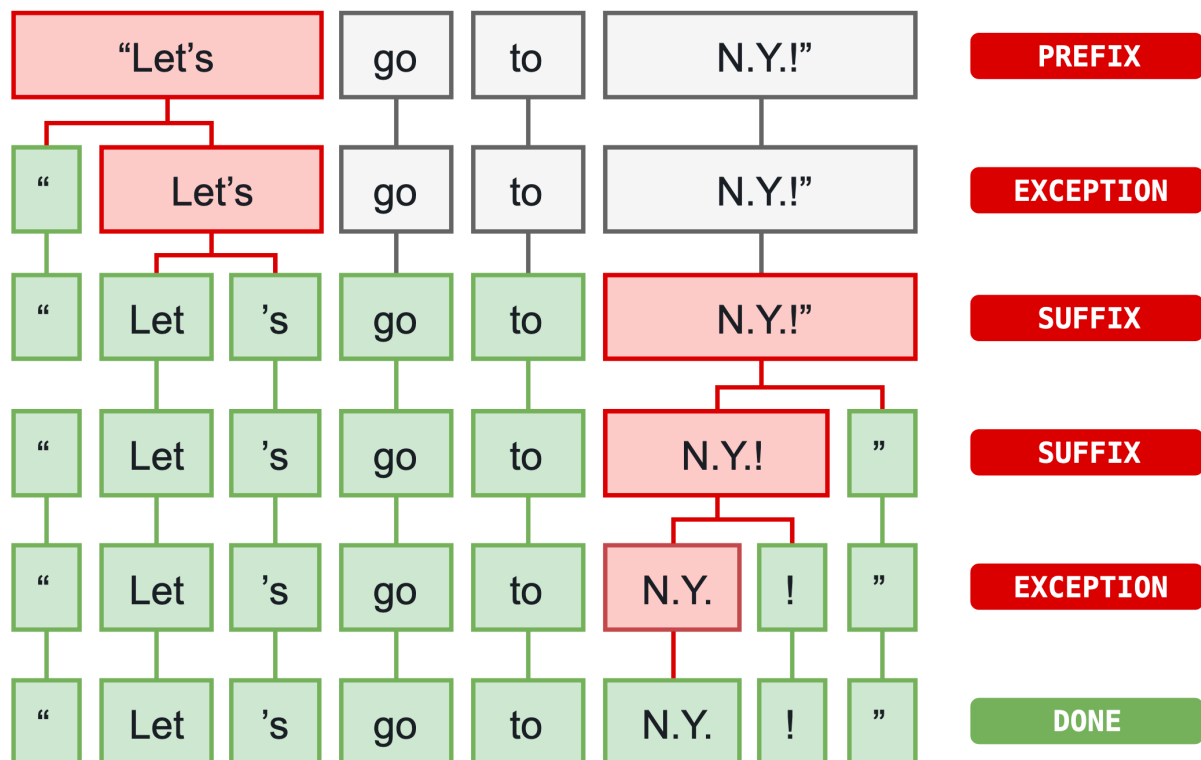


Figura 3: Transiciones del modelo Stack-LSTM indicando la acción aplicada y el estado resultante.

### 3.4. Modelos basados en reglas

Antes de entrar en detalles de cómo trabaja el modelo estadístico de spacy y entender sus fortalezas es importante esbozar brevemente el grupo de algoritmos más «naive» posible. El de los modelos basados en reglas fijas.

En estos modelos se implementan reglas finitas o expresiones regulares para la detección de las entidades. Las principales limitaciones de este enfoque son:

- **Mucho trabajo manual:** el sistema RB exige un profundo conocimiento del dominio, este análisis debe ser realizado por humanos expertos en el dominio.
- **Consumo de tiempo:** la generación de reglas para un sistema complejo es bastante difícil y requiere mucho tiempo.
- **Menor capacidad de aprendizaje:** el sistema generará el resultado según las reglas, por lo que la capacidad de aprendizaje del sistema por sí mismo es baja.



- **Dominios complejos:** si el corpus demasiado complejo, la creación del sistema RB puede llevar mucho tiempo y análisis. La identificación de patrones complejos es una tarea desafiante en el enfoque RB.

### 3.5. Modelos de «*deep-learning*»

Cuando se busca mejorar el aprendizaje automático, generalmente se piensa en la eficiencia y la precisión, pero la dimensión más importante es la generalidad. Este es el modelo estadístico que usa spaCy.

La mayoría de los problemas de NLP pueden reducirse a problemas de aprendizaje automático que toman uno o más textos como entrada. Si podemos transformar estos textos en vectores, podemos reutilizar soluciones de aprendizaje profundo (*deep-learning*) de propósito general.


Las representaciones de palabras embebidas (*embeded-words*), también conocidas como «vectores de palabras» (*word-vectors*), son una de las tecnologías de procesamiento de lenguaje natural más utilizadas en el estado del arte actual. El modelo de deep learning utilizado por spaCy puede ser descrito en 4 pasos.

Los *word-embeddings* permiten tratar a las palabras individuales como *unidades de significado*, en lugar de identificaciones completamente distintas. A este proceso se le conoce como **embed**.

Sin embargo, la mayoría de los problemas de NLP requieren la comprensión de tramos de texto más largos, no solo palabras individuales. Al juntar un conjunto de *word-embeddings* en una secuencia de vectores, se usan RNN bidireccionales para codificar los vectores en una matriz de oración. Las filas de esta matriz pueden entenderse como *vectores-de-tokens*: son sensibles al contexto del token dentro de la oración. Este paso se lo llama **encode**

Finalmente mecanismo de **attend** le permite reducir la matriz de oración a un vector de oración, listo para la predicción (**predict**).

De esta manera quedan definidas las piezas que describen al modelo de spacy:



**Figura 4:** Estados posibles para las diferentes etapas de la CNN

Estos 4 procesos serán descritos en detalle en las siguientes secciones.

### 3.5.1. embed

Resuelve el problema: «todas las palabras se ven iguales para la computadora»

La idea de *word embeddings* es la de «embeber» el conjunto de tokens que componen términos con información adicional. El resultado de esta operación es una estructura abstracta que puede ser descrita como un «vector de significado».



**Figura 5:** embed

Es importante destacar que en esta etapa de *embed*; toda la información de significado es principalmente independiente del contexto en el cual está siendo utilizada y por esta razón es fácilmente obtenible del corpus no etiquetado de datos (los algoritmos pueden darse cuenta de que palabras están relacionadas entre sí de manera eficiente y no supervisada)

Esto permite al modelo poder inferir significado a partir de información no etiquetada dentro del problema en particular a resolver (el de NER).

Una tabla de *word-embeddings* mapea vectores largos binarios y esparsos en vectores cortos densos y continuos, llenos de significado relevante. Existen varias estrategias para «infundir» tokens con información adicional. Las dos fuentes mas grandes de información embebida más importantes son las de *información lingüística* y los *word-vectors*.

### 3.5.1.1. Información lingüística

El objetivo de esta etapa es la de encontrar las características intrínsecas de cada palabra. Las principales características lingüísticas detectadas estan resumidas en el siguiente ejemplo:

TEXT	LEMMA	POS	TAG	DEP	SHAPE	ALPHA	STOP
Apple	apple	PROPN	NNP	nsubj	Xxxxx	True	False
is	be	VERB	VBZ	aux	xx	True	True
looking	look	VERB	VBG	ROOT	xxxx	True	False
at	at	ADP	IN	prep	xx	True	True
buying	buy	VERB	VBG	pcomp	xxxx	True	False
U.K.	u.k.	PROPN	NNP	compound	X.X.	False	False
startup	startup	NOUN	NN	dobj	xxxx	True	False
for	for	ADP	IN	prep	xxx	True	True
\$	\$	SYM	\$	quantmod	\$	False	False
1	1	NUM	CD	compound	d	False	False
billion	billion	NUM	CD	pobj	xxxx	True	False

Figura 6: características lingüísticas

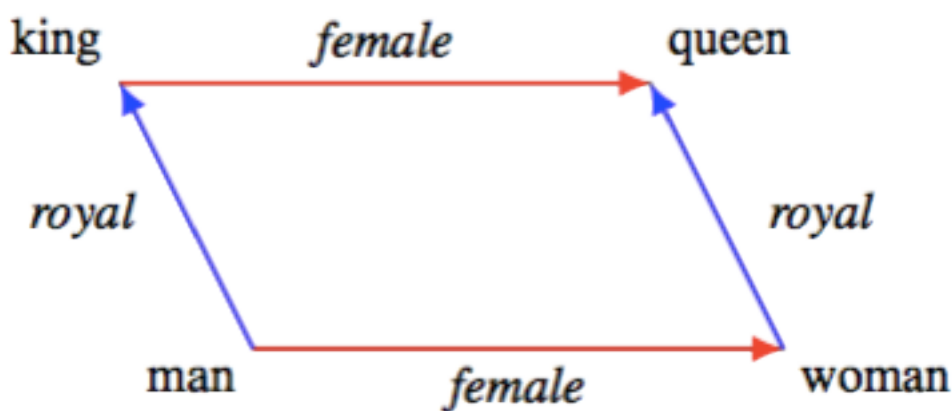
- **Text:** la palabra original texto.
- **Lemma:** La forma básica de la palabra. Es -> ser. Esto permite a las siguientes etapas trabajar con una definición canónica del token.
- **POS:** la etiqueta simple de parte-del-discurso (POS).
- **Tag:** la etiqueta detallada de parte del discurso (POS).
- **Dep:** dependencia sintáctica, es decir, la relación entre tokens.
- **Shape:** la forma de la palabra: mayúsculas, puntuación, dígitos. Muy util para detectar patrones como números telefónicos, documentos de identidad, CBUs, etc.
- **is alpha:** ¿el token es una secuencia de caracteres alfabéticos?
- **is stop:** ¿es el token parte de una lista de palabras-de-stop, es decir, las palabras más comunes del idioma?

#### 3.5.1.1.1. Word Vectors

A diferencia de la información lingüística que es obtenida en el momento. Existen otro tipo de embeddings más poderosos que son producto de preentrenamientos. Tal es el caso de los *word-vectors*. Los vectores de palabras se aprenden mediante la concatenación de incrustaciones de atributos léxicos NORM, PREFIX, SUFFIX y SHAPE. Luego se usa una capa oculta centro de una red neuronal convolucional (CNN) para permitir una combinación no lineal de la información en estos vectores concatenados.

Los vectores de palabras son particularmente útiles para términos que no están bien representados en los datos de entrenamiento etiquetados. En nuestro uso de reconocimiento de entidades, siempre habrá muchos nombres de los que no se tendrán ejemplos. Por ejemplo, en los datos de entrenamiento es posible que existan algunos ejemplos del término «Coca-Cola», pero ninguno que contenga el término «Manaos». Es interesante pensar a las palabras como «vectores de significado». Dentro del espacio vectorial de significados el vector «perro» se encuentra cercano al de «cachorro», «beagle», «bulldog», «poodle». Esto permite al modelo poder inferir nuevas relaciones en base a una cantidad reducida de input. Los vectores de palabras ponen ese hecho a disposición del modelo de reconocimiento de entidades. Si bien no existen ejemplos de «Manaos» etiquetados como «Producto»; se verá que «Manaos» tiene un vector de palabras que generalmente corresponde a los términos de un producto, por lo que puede hacer la inferencia. Y si se quiere llegar incluso al detalle de que es una Gaseosa.

Otra forma interesante de analizar y entender los *word-vectors* en su contexto de espacio vectorial multidimensional de significados es a través del álgebra de vectores, como se muestra en el Paper «Towards Understanding Linear Word Analogies» (Ethayarajh, Duvenaud, & Hirst, 2019):



**Figura 7:** Parallelogram structure in the vector space (by definition)

Es fácil de entender viendo ese paralelogramo que al realizar álgebra entre los diferentes vectores de significado se pueden inferir nuevos conceptos:

$$\begin{aligned}\vec{R\acute{e}y} - \vec{Hombre} &\approx \vec{Realeza} \\ \vec{R\acute{e}y} - \vec{Hombre} + \vec{Mujer} &\approx \vec{Reina}\end{aligned}$$

### 3.5.2. encode

Resuelve el problema: el contexto de los significados es relevante y esta siendo descartado

El resultado de esta etapa es la de encodear vectores **independientes-de-contexto** en matrices de oración **sensibles-al-contexto**




Figura 8: encode

La tecnología utilizada para esta etapa es una Red Neuronal Convolutiva en la que la oración es analizando como una *moving window* de 3 vectores en la que cada vector analiza su significado en relación con un vector previo y un vector posterior. Es decir cada vector se estudia dentro del contexto de los dos vectores que lo rodean. Luego los vectores subsiguientes se evalúan de igual manera. Por lo que se genera naturalmente un *efecto de decaimiento* en el que el contexto de los vectores más lejanos tiene una relevancia cada vez menor.

### 3.5.3. attend

Resuelve el problema: tenemos demasiada información para inferir un significado específico al problema a resolver

En esta etapa toda la información generada en las etapas anteriores es analizada a través de un vector de entrada o también conocido como *vector de consulta* o *vector de contexto* representado en la siguiente figura como un vector más oscuro.




Figura 9: attend

Al reducir la matriz a un vector, necesariamente se está perdiendo información. Es por eso que el *vector de contexto* es crucial: le dice qué información descartar, de modo que el vector «resumen» se adapte a la red que lo consume.

El análisis de estas estrategias de consulta escapa el alcance de este trabajo pero resulta un tema interesante de investigación en si mismo. Por ejemplo; investigaciones recientes han demostrado que el mecanismo de atención es una técnica flexible y que se pueden usar nuevas variaciones para crear soluciones elegantes y poderosas. Por ejemplo, en (Parikh, Täckström, Das, & Uszkoreit, 2016) presentan un mecanismo de atención que toma dos matrices de oraciones y genera un solo vector.

### 3.5.4. predict

Resuelve el problema: necesito un valor específico y no una representación genérica abstracta

Finalmente en esta etapa tenemos un nuevo *vector de significado* que resulta de la query de al etapa anterior. Necesitamos ahora traducir este *vector* a un token efectivo. En el caso de NER el token que nos interesa obtener es el de que etiqueta de entidad es la que corresponde a esta tarea.



Figura 10: predict

## 3.6. Usando el modelo estadístico

Experimentos en inglés, holandés, alemán y español muestran que se pueden obtener resultados a-la-par del estado del arte utilizando un autómata finito determinístico de pila en conjunción con una red neuronal (Lample, Ballesteros, Subramanian, Kawakami, & Dyer, 2016). En particular la red neuronal del modelo estadístico estudiado en la sección anterior.

Este autómata de pila es el nexo entre la Red Neuronal Convolutiva (CNN) que contiene el modelo estadístico para predecir entidades y el texto completo. No se envía el texto entero como input a dicha red, sino que se van enviando cada uno de los estados en los que el autómata de pila se mueve para ir generando entidades con una herística del tipo *greedy*.

Las posibles acciones de transición de este autómata son las siguientes:

$Out_t$	$Stack_t$	$Buffer_t$	Action	$Out_{t+1}$	$Stack_{t+1}$	$Buffer_{t+1}$	Segments
$O$	$S$	$(u, u), B$	SHIFT	$O$	$(u, u), S$	$B$	—
$O$	$(u, u), \dots, (v, v), S$	$B$	REDUCE( $y$ )	$g(u, \dots, v, r_y), O$	$S$	$B$	$(u \dots v, y)$
$O$	$S$	$(u, u), B$	OUT	$g(u, r_{\emptyset}), O$	$S$	$B$	—

Figura 11: Transiciones del modelo Stack-LSTM indicando la acción aplicada y el estado resultante.

- SHIFT: consume una token del input y al mueve al stack para generar una nueva entidad.
- REDUCE: mueve el stack actual al output taguado como entity.
- OUT: consume una token del input y la mueve al output directamente.

Para saber que acción tomar se consulta el modelo estadístico. En la siguiente figura se puede ver un ejemplo de cómo se recorre una oración bajo el stack propuesto:

Transition	Output	Stack	Buffer	Segment
SHIFT	[]	[]	[Mark, Watney, visited, Mars]	
SHIFT	[]	[Mark]	[Watney, visited, Mars]	
REDUCE(PER)	[(Mark Watney)-PER]	[Mark, Watney]	[visited, Mars]	
OUT	[(Mark Watney)-PER, visited]	[]	[visited, Mars]	(Mark Watney)-PER
SHIFT	[(Mark Watney)-PER, visited]	[Mars]	[Mars]	
REDUCE(LOC)	[(Mark Watney)-PER, visited, (Mars)-LOC]	[]	[]	(Mars)-LOC

**Figura 12:** Secuencia de transiciones para el ejemplo "Mark Watney visited Mars." en el modelo de Stack-LSTM.

- Primero se empieza con un stack vacío.
- Se consume «Mark» y la CNN predice que es una posible Persona. Lo envía al stack.
- Se consume «Watney» y la CNN predice que es una posible continuación de Persona. Lo envía al stack.
- Se consume «visited» y la CNN predice que esto no forma parte de una entidad. Por lo tanto antes se REDUCE la entidad «Mark Watney» del stack actual.
- Análogamente se detecta la entidad «Mars»

## 4. NERd (Implementación)

Definido el problema, queda claro que la creación de un modelo entrenado es de vital importancia para cualquier problema de tagueo de entidades. Es por ello que en el presente proyecto final hemos creado una herramienta para el entrenamiento eficiente de modelos estadísticos así como también una interfaz y API para poder consultar entidades. El nombre de esta herramienta es **NERd**, sigla cuyo significado en inglés es **Named Entity Recognition Duh**<sup>1</sup>!

Para organizar este capítulo vamos a realizar una descripción basada en el modelo de vistas de arquitectura 4+1.

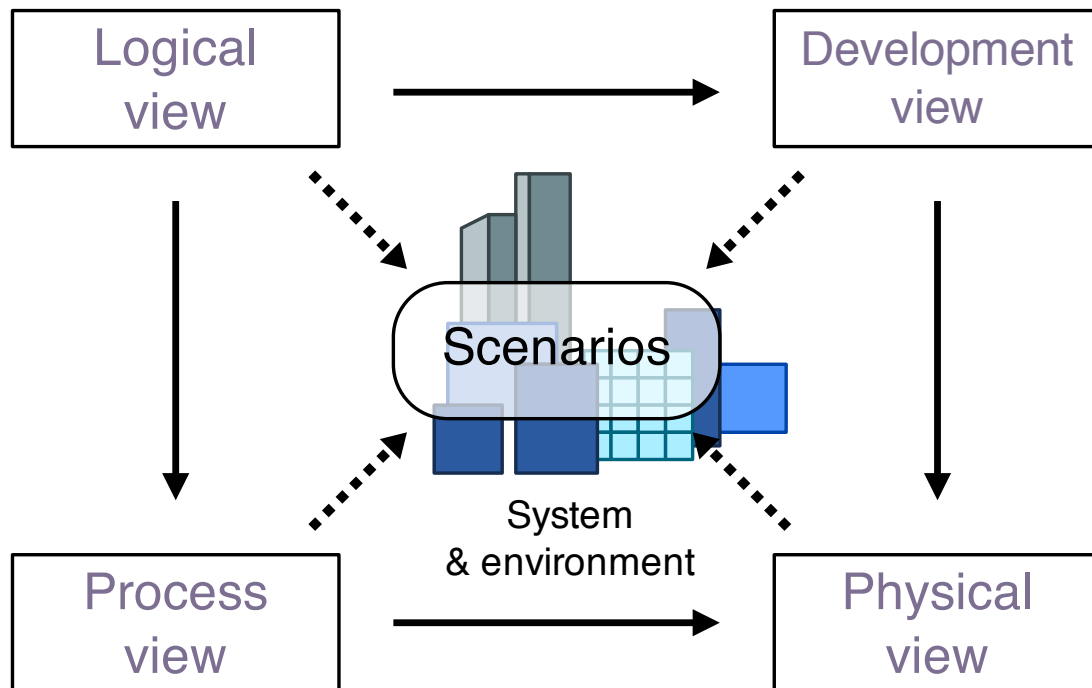


Figura 13: Ilustración de arquitectura 4+1

Este modelo nos permite describir la aplicación de una manera genérica y ordenada.

*The «4+1» view model is rather «generic»: other notations and tools can be used, other design methods can be used, especially for the logical and process decompositions, but we have indicated the ones we have used with success.*

— (Kruchten, 1995)

### 4.1. Vista lógica

La vista lógica se refiere a la funcionalidad que el sistema proporciona a los usuarios finales.

<sup>1</sup>Expresión de obviedad. *Used to express your belief that what was said was extremely obvious* ("Duh definition," 2019)



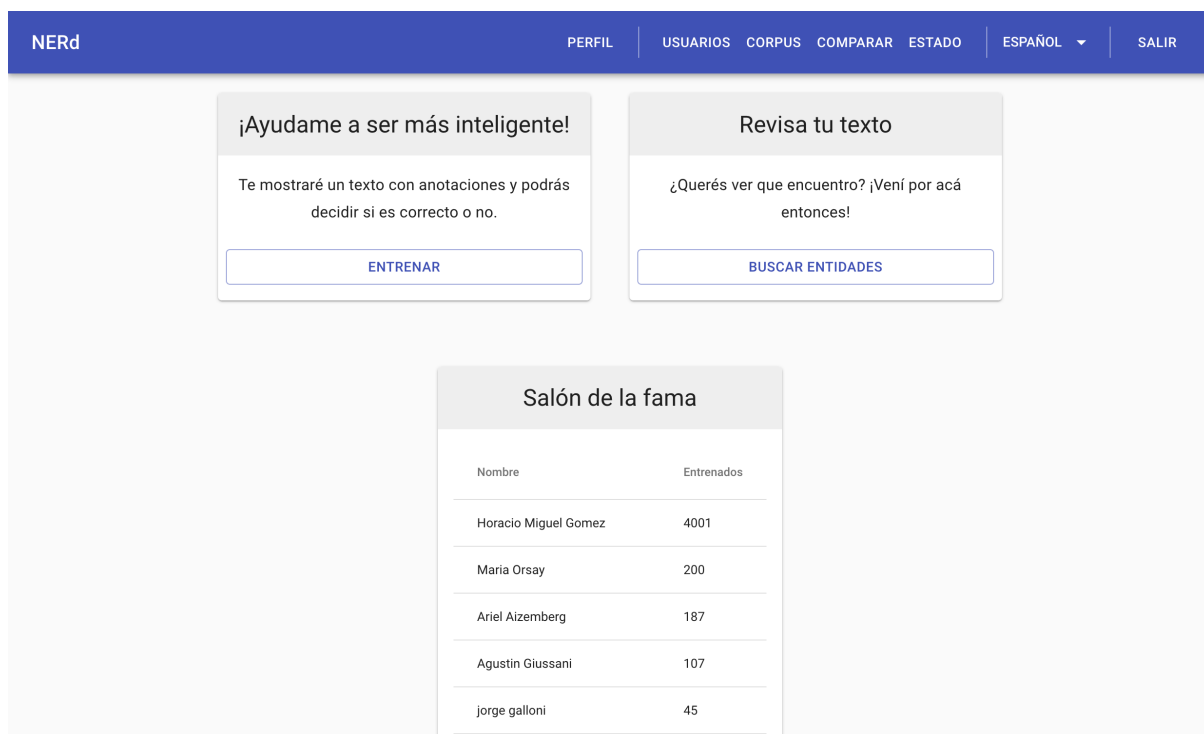
A continuación detallamos distintas partes del servicio NERd así como también de la interfaz de entrenamiento.

#### 4.1.1. Web

La página web de *NERd* está enfocada en las tareas de mantenimiento de los servicios ofrecidos por el *API* así como también ofrece de interfaces que permiten a usuarios del sistema corregir de manera eficiente el modelo de inferencia.

##### 4.1.1.1. Inicio

Pantalla de inicio donde se encuentran accesos rápidos para entrenar el modelo o para poder buscar entidades en textos. También se encuentra aquí una lista de los 5 usuarios que más contribuyeron a entrenar el modelo. Detrás de esta funcionalidad se busca generar un espíritu competitivo entre los usuarios para que los mismos busquen contribuir más.



Nombre	Entrenados
Horacio Miguel Gomez	4001
Maria Orsay	200
Ariel Aizemberg	187
Agustin Giussani	107
jorge galloni	45

**Figura 14:** Pantalla de inicio con usuario logueado

Si la persona no cuenta con permisos de entrenador, se le sugiere que contacte a un administrador para que le otorgue el permiso.




Figura 15: Pantalla de inicio sin rol de entrenador

Si la persona visitando la página no cuenta con una sesión activa, se le invita a ingresar con una cuenta pre-existente o a registrarse.




Figura 16: Pantalla de inicio sin sesión

#### 4.1.1.2. Entrenamiento

La pantalla de *Entrenamiento* es el núcleo de la web en la cual es posible entrenar el modelo.

El usuario es presentado con un texto perteneciente al Corpus del servicio con las entidades inferidas por el modelo actual. Con un editor especial, le permitimos al usuario poder corregir las entidades inferidas y enviarle la corrección al servicio. Esa corrección será utilizada posteriormente a la hora de mejorar el modelo actual.



**Figura 17:** Pantalla de entrenamiento

#### 4.1.1.2.1. Usabilidad

Tuvimos un foco fuerte en la usabilidad del widget ya que los entrenadores del servicio van a pasar prácticamente todo su tiempo en ésta pantalla, por lo que se tuvieron las siguientes consideraciones en la implementación.

Llamado a acción y ayuda

Dado que lo primero que ve el usuario es un texto con anotaciones, agregamos un título que invita al usuario a realizar acciones sobre el texto. De esta manera, le mostramos las dos acciones principales realizables desde el widget de entrenamiento: Click en alguna palabra o entidad y arrastrar un conjunto de palabras para crear una entidad nueva. Como refuerzo de este llamado a acción, agregamos un botón que al ser clickeado muestra un mensaje de ayuda con instrucciones más detalladas sobre el objetivo del entrenador y las acciones que deben de realizarse sobre el mismo.



**Figura 18:** Ayuda del entrenador

### Creación y edición de entidades

Para la creación de entidades decidimos ofrecer dos maneras: La primera es arrastrando un conjunto de palabras de manera tal de unir las todas en una única entidad. La otra es hacer click en una palabra y ahí se ofrecen opciones dependiendo de la ubicación de la palabra dentro del texto:

- Si no existen entidades en el texto actual, se le asigna por defecto el tipo *MISC* y se muestran el resto de los tipos para permitir cambiarlo de ser necesario.
- Si existen entidades antes o después, se ofrece la opción de unir la palabra actual con la entidad más próxima para el lado elegido.



Figura 19: Edición de entidad

Para la edición de entidades decidimos permitir únicamente la modificación del tipo de una entidad inferida. Si el modelo inferió una entidad de manera incorrecta, ya sea por que sea una entidad inválida o agregó palabras de más a una entidad inválida, permitimos que el usuario remueva la entidad y que después vuelva a agregar la entidad correcta.

Optimización en tiempos de carga

Dado que es esperado que un usuario entrene más de un texto, al momento de pedir un texto para mostrar, se pide el siguiente. Mediante este mecanismo de pre-carga, podemos eliminar el tiempo de espera entre texto y texto ofreciendo al usuario una experiencia completamente fluida.

#### 4.1.1.3. Administración de usuarios

La pantalla de *Administración de usuarios* permite a los usuarios con el rol de administrador poder modificar los roles de todos los usuarios del sistema, borrarlos o acceder a los detalles del usuario, tal como la lista de textos entrenados.

Administración de usuarios				
PERFIL   USUARIOS   CORPUS   COMPARAR   ESTADO   ESPAÑOL ▾   SALIR				
Usuarios <span>🔍 Search...</span>				
<input type="checkbox"/>	Nombre	Email	Roles	Entrenamientos
<input type="checkbox"/>	Admin	admin@example.com	user ▾	0
<input type="checkbox"/>	Juan Pablo Orsay	jorsay@itba.edu.ar	user trainer admin ▾	19
<input type="checkbox"/>	Horacio Miguel Gomez	hogomez@itba.edu.ar	user trainer admin ▾	4001
<input type="checkbox"/>	Martin	mcapparelli@itba.edu.ar	user trainer ▾	0
<input type="checkbox"/>	Pablo Alejandro Costesich	pablo.costesich@gmail.com	user trainer ▾	0
<input type="checkbox"/>	Ariel Aizemberg	aaizemberg@itba.edu.ar	user trainer admin ▾	187
<input type="checkbox"/>	Cris	cristian@elciudadano.cl	user ▾	0
<input type="checkbox"/>	Alejandro Vaisman	alejandro.vaisman@gmail.com	user ▾	0

Figura 20: Administración de usuarios

#### 4.1.1.4. Detalles de usuario

La pantalla de detalle de usuario permite al usuario con sesión activa ver sus entrenamientos y cambiar su contraseña.

Los usuarios con rol administrador pueden realizar las acciones mencionadas previamente pero a otros usuarios.

 Mi perfil

PERFIL | USUARIOS | CORPUS | COMPARAR | ESTADO | ESPAÑOL ▾ | SALIR

Cambiar contraseña

Contraseña \*

Confirmar contraseña \*

ACTUALIZAR

Entrenamientos

☐

Entrenamientos

☐

PER Matías Martin

 habló de la desvinculación de 

PER Cabito

 de " Basta de Todo " : "  
Es una decisión dolorosa , de la cual me hago ...

☐

En 

DATE 2018

 , el 

MISC déficit comercial

 con 

LOC Brasil

 se redujo a la mitad

☐

La reacción del 

PER Papa

 cuando una joven interrumpió su audiencia y se puso a jugar

☐

La ciencia empieza a entender el 

MISC alzhéimer


☐

Acusan a empleados de un súper de golpear y matar a un jubilado que había robado chocolates , un queso y una botella de aceite

Figura 21: Perfil de usuario

#### 4.1.1.5. Corpus

La pantalla de *Corpus* permite a un usuario con el rol de administrador realizar tareas relacionadas con el corpus del sistema.

 Corpus

PERFIL | USUARIOS | CORPUS | COMPARAR | ESTADO | ESPAÑOL ▾ | SALIR

Subir

SUBIR ARCHIVO

Textos

<input type="checkbox"/>	Texto	Añadido	Entrenamientos
<input type="checkbox"/>	[Elecciones 2019] Bomba electoral: en Córdoba, el PJ ganó en 28 comunas gobernadas por otros partidos	28 de agosto de 2019 22:47	0
<input type="checkbox"/>	¿Acto fallido?: "Nuestro candidato es María Eug... Macri"	28 de agosto de 2019 22:47	1
<input type="checkbox"/>	¿Cómo combatir las noticias falsas durante las elecciones en Argentina?	28 de agosto de 2019 22:47	1
<input type="checkbox"/>	¿Cómo combatir las noticias falsas?	28 de agosto de 2019 22:47	0
<input type="checkbox"/>	¿Cómo entender los resultados de las elecciones en Córdoba?	28 de agosto de 2019 22:47	1
<input type="checkbox"/>	¿Cómo votan los jóvenes? Pistas para entender las demandas de este electorado	28 de agosto de 2019 22:47	1
<input type="checkbox"/>	¿Cuál es la diferencia entre el voto en blanco, el voto nulo e impugnado?	28 de agosto de 2019 22:47	0
<input type="checkbox"/>	¿Cuáles son las dos opciones que tiene Sergio Massa en estas elecciones?	28 de agosto de 2019 22:47	1

Figura 22: Administración de corpus

Desde aquí es posible agregar textos al corpus utilizando la funcionalidad de subida de archivos. Los archivos deben ser archivos con extensión *.txt* y cada línea del archivo será agregada al corpus como un texto individual.

También es posible desde aquí ver todos los textos que forman parte del corpus así como también poder ver los entrenamientos para cada uno de los textos. Finalmente, es posible quitar textos del corpus así como también es posible eliminar correcciones a las inferencias de entidades cargados por usuarios.

#### 4.1.1.6. Estado

La pantalla de *Estado* permite a un usuario con el rol de administrador visualizar el estado de entrenamiento del corpus así como también realizar diversas acciones sobre los *workers*.

The screenshot shows the 'Administración del Corpus' interface. On the left, under 'Corpus', there are statistics: 'Estado: 4589 de 43751 entrenados', 'Total entrenados: 4590', and 'Sin entrenar: 0'. A 'VER' button is next to 'Corpus'. The main section is titled 'Crear snapshot'. It has a 'Tipos:' section with buttons for 'DATE Date', 'LOC Location', 'MISC Miscellaneous', 'ORG Organization', 'PER Person', and a 'NUEVO' button. Below this is a 'CREAR' button. A 'Snapshots' table is shown with columns: Version, Creado el, Último entrenamiento, Estado, Trabajadores, and Acciones. The table contains four rows: 'Actual' (created 7 de octubre de 2019 17:02, estado 'Listo', 1 worker), '1' (created 7 de octubre de 2019 7:59, estado 'Listo', 1 worker), '2' (created 7 de octubre de 2019 8:57, estado 'Listo', Ninguno workers), and '3' (created 7 de octubre de 2019 8:57, estado 'Entrenando', Ninguno workers). Below the table is a 'Reasignar trabajador' section with a dropdown menu showing 'vCURRENT' and 'a v1', and an 'APLICAR' button.

Version	Creado el	Último entrenamiento	Estado	Trabajadores	Acciones
Actual	7 de octubre de 2019 17:02	hace 3 horas	Listo	1	
1	7 de octubre de 2019 7:59	hace un mes	Listo	1	
2	7 de octubre de 2019 8:57	Nunca	Listo	Ninguno	
3	7 de octubre de 2019 8:57	hace 5 días	Entrenando	Ninguno	

Figura 23: Información de corpus y manejo de workers

##### 4.1.1.6.1. Secciones

###### Corpus

Es la columna la izquierda y aquí se puede ver rápidamente que porcentaje de el corpus contiene correcciones por usuarios así como también saber la cantidad total de correcciones del sistema (un texto puede tener más de una corrección por distintos usuarios) y también presenta un botón que permite al administrador ir a la pantalla de *Corpus*.

###### Crear snapshot

Es la sección en la cual será posible crear, borrar o modificar los tipos de entidades reconocidos por el snapshot actual. La acción de editar las entidades genera un snapshot nuevo.

Si el administrador así lo quisiera, puede utilizar esta sección para crear un snapshot nuevo sin editar entidades.



## Snapshots

Sección en la cual podemos ver la lista completa de snapshots. Para cada Snapshot, se muestra cuando fue la última vez que se entrenó así como también cuantos trabajadores tiene asignados. Finalmente es posible desde aquí forzar a entrenar el modelo para ese snapshot en particular y también se presenta la opción para desentrenar, borrando el modelo guardado en el disco.

## Reasignar trabajador

Sección que permite reasignar trabajadores para que sirvan un snapshot distinto. De esta manera se pueden servir distintas versiones del modelo de inferencia para poder realizar distintas pruebas sobre los mismos.

### 4.1.1.7. Sandbox

La pantalla de *Sandbox* permite a los usuarios hacer consultas al servicio NERd para poder obtener entidades nombradas a partir de textos arbitrarios. Adicionalmente, si el usuario tiene el rol de entrenador, podrá corregir las entidades inferidas y agregar el texto con sus correcciones al corpus.

The screenshot displays the 'Sandbox de NER' interface. At the top, a blue navigation bar contains a home icon, the title 'Sandbox de NER', and several menu items: 'PERFIL', 'USUARIOS', 'CORPUS', 'COMPARAR', 'ESTADO', 'ESPAÑOL' (with a dropdown arrow), and 'SALIR'. Below the navigation bar, the main content area is divided into two sections. The upper section is a text input area with a placeholder 'Texto' and a sample sentence: 'El director técnico argentino Mauricio Pochettino fue despedido este martes por el Tottenham de Inglaterra, club al que dirigió durante cinco años y al que condujo a la final de la pasada edición de la Champions League.' To the right of this input area is a blue button labeled 'BUSCAR ENTIDADES'. The lower section displays the results of the search. The same sentence is shown, but with entities highlighted and labeled: 'PER' for 'Mauricio Pochettino', 'ORG' for 'Tottenham', 'LOC' for 'Inglaterra', and 'MISC' for 'Champions League'. To the right of the results is a blue button labeled 'GUARDAR'.

Figura 24: Inferencia de entidades en sandbox

### 4.1.1.8. Comparar

Sección accesible únicamente a administradores en la que es posible comparar las entidades inferidas por dos modelos distintos. A su vez, si el usuario logueado tiene el permiso de entrenador, es posible corregir de manera inline los errores en la inferencia del modelo actual.



Figura 25: Comparativa de modelos

#### 4.1.2. Servicio

El acceso al servicio se realiza mediante un API REST que se auto-documenta debido a implementar la especificación de OpenAPI. A continuación detallamos los endpoints.

##### 4.1.2.1. Autenticación

Rutas del API dedicadas a la autenticación de usuarios.

- **POST** `/api/auth/register`
  - Registrar un usuario nuevo.
- **POST** `/api/auth/token`
  - Genera un nuevo token de acceso y refresco con credenciales.
  - Utilizado para la funcionalidad de *login*
- **POST** `/api/auth/refresh`
  - Refresca el token de acceso.
  - Utilizado cuando un token de acceso caducó.

##### 4.1.2.2. Usuarios

Conjunto de operaciones relacionadas con los usuarios del sistema.

- **GET** `/api/users`
  - Lista de usuarios existentes
  - Separa los resultados en páginas
- **GET** `/api/users/top5`

- Lista de los 5 usuarios con más entrenamientos
- **GET** */api/users/me*
  - Retorna la información del usuario logueado
- **PATCH** */api/users/me*
  - Actualiza la información del usuario logueado
- **GET** */api/users/me/trainings*
  - Retorna los entrenamientos del usuario logueado
  - Separa los resultados en páginas
- **GET** */api/users/{user\_id}*
  - Retorna la información del usuario especificado por *user\_id*
- **PATCH** */api/users/{user\_id}*
  - Actualiza la información del usuario especificado por *user\_id*
- **DELETE** */api/users/{user\_id}*
  - Borra al usuario especificado por *user\_id*
- **GET** *\_api/users/{user\_id}/trainings*
  - Retorna los entrenamientos del usuario especificado

#### 4.1.2.3. Roles

- **GET** */api/roles*
  - Retorna la lista de todos los roles asignables a usuarios del sistema

#### 4.1.2.4. Corpus

Rutas dedicadas a operaciones con el corpus del sistema.

- **GET** */api/corpus/{text\_id}*
  - Retorna los detalles del texto especificado por *text\_id*
- **DELETE** */api/corpus/{text\_id}*
  - Borra un texto especificado por *text\_id* del corpus
- **GET** */api/corpus/{text\_id}/trainings*
  - Retorna la lista de entrenamientos proporcionados por los usuarios sobre las entidades en el texto
- **PUT** */api/corpus/{text\_id}/trainings*
  - Agrega un entrenamiento para el texto con id *text\_id*
- **POST** */api/corpus/upload*
  - Permite agregar textos de manera masiva al sistema
  - Acepta una lista de archivos .txt donde cada línea es un texto a agregar
  - Los archivos deben ser UTF-8
- **GET** */api/corpus*
  - Lista de textos cargados en el sistema para entrenamiento
  - Separa los resultados en páginas
- **POST** */api/corpus*
  - Agrega un texto al sistema para entrenamiento

#### 4.1.2.5. Snapshots

Conjunto de operaciones relacionadas con los snapshots y workers.

- **GET** /api/snapshots
  - Listado de los snapshots disponibles
  - Separa los resultados en páginas
- **GET** /api/snapshots/{snapshot\_id}
  - Retorna información (tipos de entidades, fecha de creación, fecha de entrenamiento, etc.) sobre un snapshot específico
- **DELETE** /api/snapshots/{snapshot\_id}
  - Borra un snapshot con el id especificado
- **POST** /api/snapshots/{snapshot\_id}/force-train
  - Envía la tarea de entrenamiento a los workers que tienen el snapshot *snapshot\_id* cargado.
- **POST** /api/snapshots/{snapshot\_id}/force-untrain
  - Envía la tarea de desentrenar a los workers que tienen el snapshot *snapshot\_id* cargado.
- **GET** /api/snapshots/current
  - Retorna información sobre el snapshot actual
- **PUT** /api/snapshots/current
  - Crea un nuevo snapshot con la información provista

#### 4.1.2.6. Reconocimiento de Entidades Nombradas

Conjunto de operaciones relacionadas al *Reconocimiento de Entidades Nombradas*

- **GET** /api/ner/train
  - Retorna un texto para que un usuario del sistema revise si está correctamente inferido
  - Únicamente retorna textos que el usuario logueado no haya corregido ya
- **GET** /api/ner/compare/{first\_snapshot}/{second\_snapshot}
  - Compara el *Reconocimiento de Entidades Nombradas* entre dos snapshots distintos
- **POST** /api/ner/current/parse
  - Retorna un documento Spacy para un texto dado utilizando el snapshot actual
- **POST** /api/ner/{snapshot\_id}/parse
  - Retorna un documento Spacy para un texto dado utilizando el snapshot especificado
- **POST** /api/ner/current/entities
  - Retorna la lista de *Entidades Nombradas* para un texto dado utilizando el modelo actual
- **POST** /api/ner/{snapshot\_id}/entities
  - Retorna la lista de *Entidades Nombradas* para un texto dado utilizando el modelo especificado

#### 4.1.2.7. Entrenamientos

- **DELETE** /api/trainings/{training\_id}
  - Borra un entrenamiento

#### 4.1.2.8. Workers

- **GET** /api/workers/
  - Lista de los workers disponibles
- **POST** /api/workers/reassign
  - Reasigna un trabajador de un a versión de snapshot a otra

## 4.2. Vista de proceso

La vista de proceso trata los aspectos dinámicos del sistema, explica los procesos del sistema y cómo se comunican, y se centra en el comportamiento del sistema en tiempo de ejecución. La vista de proceso aborda concurrencia, distribución, integradores, rendimiento y escalabilidad, etc.

Existen cinco procesos que juntos forman la totalidad de NERd y su entrenador.

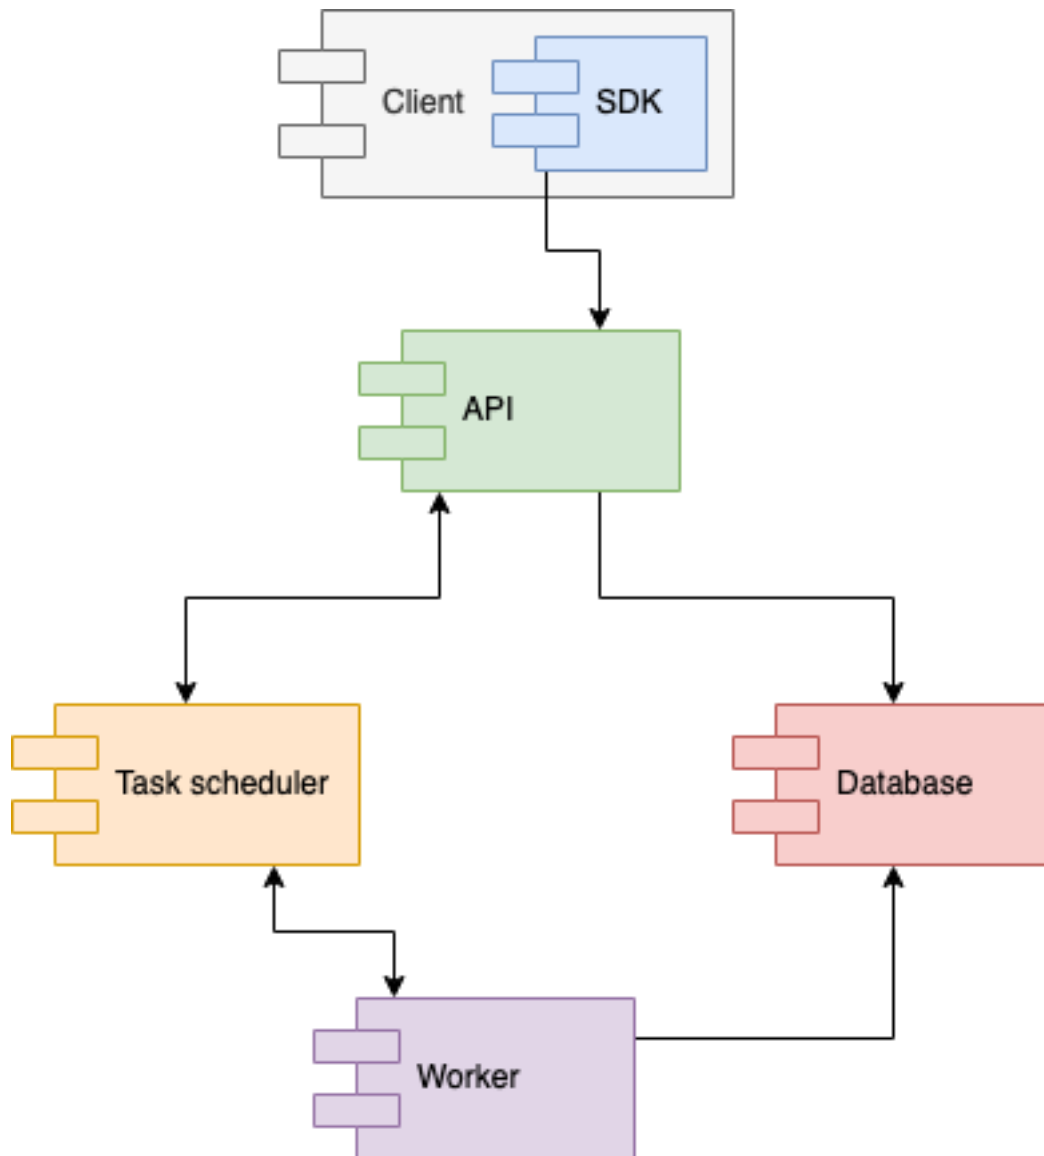


Figura 26: Componentes del sistema

### 4.2.1. API

Servicio en el cual los clientes pueden pedir las *Entidades Nombradas* de textos así como también permite la carga de textos con sus respectivas correcciones que luego serán utilizadas para entrenar el modelo de inferencia. El API se comunica el servicio de *Bases de Datos* para obtener o modificar

información sobre los usuarios, los textos pertenecientes al corpus o información de los distintos *snapshots* y con el *Task Scheduler* para realizar diversas tareas relacionadas con *Spacy*.

#### 4.2.2. Task Scheduler

Recibe tareas desde el *API* tales como reconocer entidades, entrenar y desentrenar un modelo, cambiar el modelo de un worker entre otras. Dado que su tarea es recibir tareas desde el *API* y enviar y recibir mensajes de los *Workers*, debería existir una única instancia del mismo. A su vez, notifica al *API* la finalización de tareas asincrónicas

#### 4.2.3. Worker

Un *Worker* se encarga de realizar el *Reconocimiento de Entidades Nombradas* así como también de entrenar modelos de inferencia. Es un servicio que existe de manera independiente y necesita de dos otros servicios para funcionar:

- *Base de datos* para obtener los datos necesarios para entrenar un modelo.
- *Task scheduler* para poder recibir tareas.

Como el *Worker* es una unidad de trabajo que recibe tareas desde el *Task Scheduler*, es posible tener varios *Workers* donde cada uno utiliza un modelo de inferencia distinto (generados a partir de distintos snapshots).

#### 4.2.4. Database

Servicio que contiene la base de datos con la información necesaria (usuarios, snapshots) para que el servicio de *API* funcione así como también los datos necesarios por los workers (entrenamientos).

#### 4.2.5. Cliente

Es la interfaz del entrenador que se comunica con el *API* utilizando un SDK auto-generado a partir de la definición de *OpenAPI*. Implementado en este proyecto es un cliente web el cual permite explotar las funcionalidades de entrenamiento así como de inferencia de entidades

### 4.3. Vista de desarrollo

La vista de desarrollo ilustra un sistema desde la perspectiva de un programador y se ocupa de la gestión de software. Esta vista también se conoce como la vista de implementación.

#### 4.3.1. Web

La página web que contiene la interfaz de administración así como también la de entrenamiento. Para implementarla decidimos utilizar el modelo de *Single Page Application* que nos permitió gene-

rar un *bundle* que puede ser hosteado en *CDNs* y nos permite tener ciclos de release independientes al los del servicio.

Poder separar las releases de la web y el servicio es importante ya que los clientes del servicio no necesariamente necesitan de la web, ya que pueden acceder al servicio mediante el *API REST* y una baja por cambios a la interfaz de la web no afecta la disponibilidad del servicio.

#### 4.3.1.1. Tecnologías

Para la implementación utilizamos el lenguaje de programación llamado **Typescript**, lenguaje desarrollado por *Microsoft* que compila a *JavaScript* con el agregado de *Tipos* que permiten producir código de mayor calidad debido al agregado de la posibilidad del chequeo estático de código para validar su correctitud.

Una vez definido el lenguaje, optamos por utilizar la librería llamada **ReactJS** (Facebook, 2019) desarrollada por *Facebook* para implementar la interfaz.

Sumado a **ReactJS**, incluimos diversas librerías para poder resolver varios problemas en el desarrollo de una *SPA*:

##### 4.3.1.1.1. Material UI

Provee de una biblioteca de componentes estilados siguiendo el patrón de diseño propuesto por *Google* llamado *Material Design*.

##### 4.3.1.1.2. React Router

Desarrollada por *React Training*, provee de mecanimos para la navegación en *SPAs*.

##### 4.3.1.1.3. i18next

Librería que provee mecanismos de internacionalización. A su vez, nos permitió generar los archivos de traducción mediante su extracción del código fuente utilizando la herramienta *i18next-scanner*.

##### 4.3.1.1.4. OpenAPI Generator


*OpenAPI Generator* es una herramienta que permite generar código a partir de una definición de *OpenAPI*. Debido a que el servicio implementado expone una definición de *OpenAPI*, podemos utilizar ésta librería para auto-generar todo el código necesario para comunicarnos con el servicio usando el generador de *Typescript*.

## 4.4. Vista física

La vista física representa el sistema desde el punto de vista de un ingeniero de sistemas. Se refiere a la topología de los componentes de software en la capa física, así como a las conexiones físicas entre estos componentes. Esta vista también se conoce como la vista de *deployment*.

## 4.5. Escenarios

La descripción de una arquitectura se ilustra utilizando un pequeño conjunto de casos de uso, o escenarios, que se convierten en una quinta vista. Los escenarios describen secuencias de interacciones entre objetos y entre procesos. Se utilizan para identificar elementos arquitectónicos y para ilustrar y validar el diseño de la arquitectura. También sirven como punto de partida para las pruebas de un prototipo de arquitectura. Esta vista también se conoce como vista de caso de uso.





## 5. Resultados

Matriz de confusión -> dos indicadores! true positive vs true negative Credibility: evaluation whats been leaerned.

### 5.1. Métrica: precisión y exhaustividad

("Precision and recall," 2019)

TODO: reescribir

En conferencias académicas como CoNLL, se ha definido una variante del [[valor-F]] de la siguiente manera:

- Precisión es el número de entidades nombradas que coinciden exactamente con conjunto de evaluación. I.e. cuando se predice [Persona Hans] [Persona Blick], pero lo correcto era [Person Hans Blick], la precisión es cero. La precisión es después promediada por cada una de la entidades nombradas.
- El recobrado es el número de entidades del conjunto de evaluación que aparecen exactamente en la misma posición en las predicciones.
- El Valor-F es la media armónica de estos dos valores. Se deriva de la anterior definición que cualquier predicción que reconozca erróneamente un token como parte de una entidad nombrada o que deje de detectar un token que sí es una entidad nombrada o lo clasifique erróneamente no contribuirá ni a la precisión ni al recobrado.

=== Evaluación formal === Para evaluar la calidad de la salida de un sistema NER, se han definido varias medidas. Las medidas habituales se llaman [[Precision\_and\_recall | Precisión, recuperación]] y [[Puntuación F1]]. Sin embargo, quedan varios problemas sobre cómo calcular esos valores.

Estas medidas estadísticas funcionan razonablemente bien para los casos obvios de encontrar o faltar una entidad real exactamente; y para encontrar una no entidad. Sin embargo, NER puede fallar de muchas otras maneras, muchas de las cuales son posiblemente «parcialmente correctas», y no deben considerarse como éxitos o fracasos competitivos. Por ejemplo, identificar una entidad real, pero: \* con menos tokens de los deseados (por ejemplo, falta el último token de «John Smith, M.D.») \* con más tokens de los deseados (por ejemplo, incluyendo la primera palabra de «The University of MD») \* particionando entidades adyacentes de manera diferente (por ejemplo, tratando a «Smith, Jones Robinson» como entidades 2 vs. 3) \* asignarle un tipo completamente incorrecto (por ejemplo, llamar a un nombre personal a una organización) \* asignándole un tipo relacionado pero inexacto (por ejemplo, «sustancia» vs. «droga», o «escuela» vs. «organización») \* identificar correctamente una entidad, cuando lo que el usuario quería era una entidad de menor o mayor alcance (por ejemplo, identificar «James Madison» como un nombre personal, cuando forma parte de la «Universidad James Madison»). Algunos sistemas NER imponen la restricción que las entidades nunca se superpongan o aniden, lo que significa que en algunos casos uno debe tomar decisiones arbitrarias o específicas de la tarea.

Un método demasiado simple para medir la precisión es simplemente contar qué fracción de todas las fichas en el texto se identificaron correcta o incorrectamente como parte de referencias de entidad (o como entidades del tipo correcto). Esto tiene al menos dos problemas: en primer lugar,

la gran mayoría de los tokens en el texto del mundo real no forman parte de los nombres de las entidades, por lo que la precisión de la línea de base (siempre predice «no una entidad») es extraordinariamente alta, típicamente > 90 %; y segundo, predecir erróneamente el lapso completo del nombre de una entidad no se penaliza adecuadamente (encontrar solo el nombre de una persona cuando le sigue su apellido podría calificarse como  $\frac{1}{2}$  precisión).

En conferencias académicas como CoNLL, una variante de la [[puntuación F1]] se ha definido de la siguiente manera: {{r | conll03intro}}

- [[Precisión y recuperación | Precisión]] es el número de intervalos de nombre de entidad pronosticados que se alinean “ exactamente ” con intervalos en los datos de evaluación [[Verdad fundamental # Estadísticas y aprendizaje automático | estándar de oro]]. Es decir, cuando se predice [ Persona Hans] [ Persona Blick] pero se requiere [ Persona Hans Blick], la precisión del nombre predicho es cero. La precisión se promedia sobre todos los nombres de entidad pronosticados.
- Recordar es igualmente el número de nombres en el estándar de oro que aparecen exactamente en la misma ubicación en las predicciones.
- La puntuación F1 es la [[media armónica]] de estos dos.

De la definición anterior se deduce que cualquier predicción que omita un solo token, incluye un token espurio o tiene clase incorrecta, es un error difícil y no contribuye positivamente ni a la precisión ni a la recuperación. Por lo tanto, se puede decir que esta medida es pesimista: puede darse el caso de que muchos «errores» estén cerca de ser correctos, y podrían ser adecuados para un propósito dado. Por ejemplo, un sistema siempre puede omitir títulos como «Sra.» o «Ph.D.», pero se compara con un sistema o datos de verdad que esperan que se incluyan títulos. En esos casos, cada nombre se trata como un error. Debido a tales problemas, es importante examinar los tipos de errores y decidir qué tan importantes se les dan los objetivos y requisitos.

## 6. Discusión

### 6.1. Tipos de entidades relevantes

tener en cuenta (Brunstein, 2002)

# Notas sobre mejora en tipos de entidades

Presidente -> Person Descriptor

NORP -> (Polical) Peronistas, Kirchneristas

Facility Name -> usually location. "Wall Street", "Muralla China"

Organization Name -> Government vs Corporation.

Product Name -> autos "Fiat Toro", celulares "Galaxy S10"

Events -> Superclásico. Superliga. Copa argentina. Elecciones 2019. Las Paso.

Disease ->

Game -> Football, Basket (para "titulos" no tan relevante)

### 6.2. Seed en los types

en especial para los nuevos.

### 6.3. Linkeo de entidades con Knowledge Base

La tarea de reconocer entidades nombradas en el texto es Reconocimiento de entidades nombradas, mientras que la tarea de determinar la identidad de las entidades nombradas mencionadas en el texto se llama Desambiguación de entidades nombradas. Ambas tareas requieren algoritmos y recursos dedicados para ser abordados. [3]

### 6.4. Mejora live vs offline

Mejora «Uncertainty sampling» -> buscar entidades que tengan un score ~ 0.5

### 6.5. Utilidad de la herramienta

Para poder poner a prueba nuestra herramienta **NERd** en un entorno real participamos de la hackaton en MediaParty 2019.

(**"Hackaton," 2019**) es un evento de tres días en Argentina, que reúne a 2500 emprendedores, periodistas, programadores de software y diseñadores de cinco continentes para trabajar juntos para el futuro de los medios de comunicación. Nacido de Hacks/Hackers Buenos Aires, el evento fusiona a grandes empresas como New York Times, The Guardian, Vox, ProPublica, Watchup, Neo4J o DocumentCloud y comunidades regionales de la mayor red de periodistas y desarrolladores del mundo.

Participamos en conjunto con otro proyecto final en el que van a utilizar nuestra API para hacer detección de entidades en documentos PDF.

La experiencia fue muy satisfactoria, recibimos buenas críticas sobre la Usabilidad de nuestra aplicación y la gran utilidad que presta a la comunidad.

Por tal motivo recibimos el primer premio de dicha hackaton ("Mención itba," 2019)




Figura 27: Here is a nice figure!

## 7. Conclusiones

### 7.1. Examples

You can label chapter and section titles using `{#label}` after them, e.g., we can reference Chapter 1. If you do not manually label them, there will be automatic labels anyway, e.g., Chapter 3.

Figures and tables with captions will be placed in `figure` and `table` environments, respectively.

```
par(mar = c(4, 4, .1, .1))
plot(pressure, type = 'b', pch = 19)
```

Reference a figure by its code chunk label with the `fig:` prefix, e.g., see Figure 27. Similarly, you can reference tables generated from `knitr::kable()`, e.g., see Table 1.

```
knitr::kable(
  head(iris, 20), caption = 'Here is a nice table!',
  booktabs = TRUE
)
```

You can write citations, too. For example, we are using the **bookdown** package (Xie, 2019) in this sample book, which was built on top of R Markdown and **knitr** (Xie, 2015).

**Cuadro 1:** Here is a nice table!

Sepal.Length	Sepal.Width	Petal.Length	Petal.Width	Species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
4.7	3.2	1.3	0.2	setosa
4.6	3.1	1.5	0.2	setosa
5.0	3.6	1.4	0.2	setosa
5.4	3.9	1.7	0.4	setosa
4.6	3.4	1.4	0.3	setosa
5.0	3.4	1.5	0.2	setosa
4.4	2.9	1.4	0.2	setosa
4.9	3.1	1.5	0.1	setosa
5.4	3.7	1.5	0.2	setosa
4.8	3.4	1.6	0.2	setosa
4.8	3.0	1.4	0.1	setosa
4.3	3.0	1.1	0.1	setosa
5.8	4.0	1.2	0.2	setosa
5.7	4.4	1.5	0.4	setosa
5.4	3.9	1.3	0.4	setosa
5.1	3.5	1.4	0.3	setosa
5.7	3.8	1.7	0.3	setosa
5.1	3.8	1.5	0.3	setosa

- Brunstein, A. (2002). Annotation guidelines for answer types. Retrieved from <https://catalog.ldc.upenn.edu/docs/LDC2005T33/BBN-Types-Subtypes.html>
- Duh definition. (2019). Retrieved October 14, 2019, from <https://dictionary.cambridge.org/es/diccionario/ingles/duh>
- Ethayarajh, K., Duvenaud, D., & Hirst, G. (2019). Towards understanding linear word analogies. *Proceedings of the 57th annual meeting of the association for computational linguistics*, 3253–3262. <https://doi.org/10.18653/v1/P19-1315>
- Facebook. (2019). React: A javascript library for building user interfaces. Retrieved November 20, 2019, from <https://reactjs.org/>
- Hackaton. (2019). Retrieved August 31, 2019, from <https://mediaparty.info/>
- Honnibal, M. (2017). Practical and effective neural ner. Retrieved November 2, 2017, from [https://github.com/explosion/talks/blob/master/2017-11-02\\_Practical-and-Effective-Neural-NER.pdf](https://github.com/explosion/talks/blob/master/2017-11-02_Practical-and-Effective-Neural-NER.pdf)
- Kripke, S. (1980). *Naming and necessity*. Retrieved from <https://books.google.com.ar/books?id=9vvAlOBfq0kC>
- Kruchten, P. (1995). The 4+1 view model of architecture. *IEEE Softw.*, 12(6), 42–50. <https://doi.org/10.1109/52.469759>
- Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., & Dyer, C. (2016). Neural architectures for named entity recognition. *CoRR*, abs/1603.01360. Retrieved from <http://arxiv.org/abs/1603.01360>
- Marsh, E., & Perzanowski, D. (1998). MUC-7 evaluation of IE technology: Overview of results. *Seventh message understanding conference (MUC-7): Proceedings of a conference held in fairfax, virginia, April 29 - may 1, 1998*. Retrieved from <https://www.aclweb.org/anthology/M98-1002>
- Mención itba. (2019). Retrieved October 3, 2019, from <https://www.instagram.com/p/B3Koum2peD-/>
- Montani, I. (2016). Practical and effective neural ner. Retrieved November 28, 2016, from [https://github.com/explosion/talks/blob/master/2016-11-28\\_The-State-of-AI-2016.pdf](https://github.com/explosion/talks/blob/master/2016-11-28_The-State-of-AI-2016.pdf)
- Parikh, A., Täckström, O., Das, D., & Uszkoreit, J. (2016). A decomposable attention model for natural language inference. *Proceedings of the 2016 conference on empirical methods in natural language processing*, 2249–2255. <https://doi.org/10.18653/v1/D16-1244>
- Poibeau, T., & Kosseim, L. (2000). Proper name extraction from non-journalistic texts. *CLIN*.
- Precision and recall. (2019). Retrieved October 16, 2019, from [https://en.wikipedia.org/wiki/Precision\\_and\\_recall](https://en.wikipedia.org/wiki/Precision_and_recall)
- The state of the octoverse: Machine learning. (2019). Retrieved January 24, 2019, from <https://github.blog/2019-01-24-the-state-of-the-octoverse-machine-learning/>
- Xie, Y. (2015). *Dynamic documents with R and knitr* (2nd ed.). Retrieved from <http://yihui.name/knitr/>
- Xie, Y. (2019). *Bookdown: Authoring books and technical documents with r markdown*. Retrieved from <https://github.com/rstudio/bookdown>